

RAPPORT ANALYTIQUE

Accidents de la route aux États-Unis : une analyse statistique au service de la sécurité publique

Réalisé à : Simplon Maghreb



Réalisé par :

DAOUDI Safiya
JANAH Asmae
ET-TAHERY Zineb
MAMDOUH Hajar

Table des matières

Liste des figures	ii
Liste des tableaux	iii
Introduction générale	1
1 Description des jeux de données	2
1.1 Dataset original US-Accidents	2
1.2 Description des variables	2
1.2.1 Identification et gravité de l'accident	2
1.2.2 Informations temporelles	3
1.2.3 Localisation géographique	3
1.2.4 Conditions météorologiques	4
1.2.5 Infrastructures routières et signalisation	4
1.3 Traitements préalables des données	5
1.4 Dataset échantillonné utilisé pour les analyses	6
2 Visualisations et Interprétations	7
2.1 Condition météo et environnement	7
2.1.1 Sévérité des accidents selon la météo	7
2.1.2 Visibilité vs Sévérité	8
2.1.3 Variables météorologiques et la sévérité des accidents	10
2.1.4 Nombre d'accidents par condition météo	11
2.2 Analyse spatiale et risque géographique	13
2.2.1 Gravité des accidents par région	13
2.2.2 Répartition géographique des accidents	15
2.2.3 Gravité des accidents – Urbain vs Rural	16
2.2.4 Densité des accidents vs Gravité moyenne par État	18
2.2.5 Niveau de risque par région	20
2.2.6 Top 10 États par nombre d'accidents	21
2.2.7 Répartition des accidents par région	22
2.3 Infrastructure routière et sécurité	24
2.3.1 Sévérité des accidents selon le niveau de protection	24
2.3.2 Sévérité des accidents selon le niveau de risque	25
2.3.3 Gravité normalisée par type d'intersection :	26
2.3.4 Gravité moyenne selon le niveau de sécurité/conflit :	28
2.3.5 Relation entre l'indice de protection et la gravité	29
2.3.6 Gravité moyenne par situation critique	30
2.3.7 Effet cumulatif des infrastructures sur la gravité	32
2.4 Analyse temporelle & saisonnalité	33
2.4.1 Distribution horaire du volume d'accidents	33

2.4.2	Répartition hebdomadaire du volume d'accidents	34
2.4.3	Comparaison du volume d'accidents : Semaine vs Week-end par gravité	36
2.4.4	Analyse spatio-temporelle : Heatmap des accidents (Heure $\times$ Jour)	37
2.4.5	Évolution historique du volume d'accidents (2016-2023)	38
2.4.6	Analyse de la saisonnalité du volume d'accidents	40
2.4.7	Analyse de la durée des accidents par période de la journée	41
Conclusion générale		43

Liste des figures

1.1	Processus de Préparation des Données	5
2.1	Proportions de sévérité par météo (Bar Chart Empilé à 100%)	8
2.2	Lien Visibilité / Sévérité (Scatter Plot)	9
2.3	Corrélations Variables Météo	11
2.4	Nombre d'accidents par météo (Bar Chart)	13
2.5	Gravité par region (Box plot)	14
2.6	Répartition géographique(Scatter plot)	16
2.7	Gravité : Urbain vs Rural (Box plot)	18
2.8	Densité vs gravité par état (Scatter plot)	19
2.9	Niveau de risque par région (barres empilées)	21
2.10	Top 10 états par nombre d'accidents (Barre Chart)	22
2.11	Répartition des accidents par région (Pie Chart)	23
2.12	Impact du niveau de protection sur la variabilité et l'intensité de la gravité (Violin plot)	25
2.13	Distribution de la gravité selon le niveau de risque infrastructurel (Box plot)	26
2.14	Distribution normalisée de la gravité selon le type d'intersection (Heatmap)	28
2.15	Gravité moyenne selon le niveau de sécurité/conflit (Bar chart)	29
2.16	Indice de protection vs gravité des accidents (Scatter plot avec régression)	30
2.17	Gravité moyenne par situation critique (Bar chart)	32
2.18	Effet cumulatif des infrastructures sur la gravité moyenne (Line plot) . .	33
2.19	Évolution horaire du nombre d'accidents sur 24 heures (Line plot)	34
2.20	Volume total des accidents par jour de la semaine (Bar chart)	36
2.21	Comparaison du volume et de la gravité : Semaine vs Week-end (Bar chart empilé)	37
2.22	Concentration des accidents par heure et par jour de la semaine (Heatmap)	39
2.23	Évolution mensuelle des accidents entre 2016 et 2023 (Time series plot) .	40
2.24	Répartition du volume total d'accidents par saison (Bar chart)	41
2.25	Distribution de la durée des accidents selon la période de la journée (Box plot)	42

Liste des tableaux

1.1	Description des variables temporelles du dataset	3
1.2	Description des variables de localisation géographique du dataset	3
1.3	Description des variables météorologiques du dataset	4
1.4	Description des variables d'infrastructures routières et signalisation du dataset	4

Introduction générale

Les accidents de la route constituent un enjeu majeur de sécurité publique à l'échelle mondiale. Chaque année, ils causent des pertes humaines importantes, des blessures graves ainsi que des conséquences économiques et sociales considérables. Malgré les progrès réalisés en matière d'infrastructures, de réglementation et de technologies automobiles, les accidents de la circulation demeurent fréquents et leur gravité varie selon de nombreux facteurs. L'analyse des données liées aux accidents de la route représente ainsi un outil essentiel pour mieux comprendre ces phénomènes et contribuer à l'amélioration des politiques de prévention et de sécurité routière.

Dans ce contexte général, ce rapport s'inscrit dans un projet d'analyse statistique avancée mené par une équipe de Data Analysts, dans une démarche orientée vers le bien social. L'objectif de ce travail est d'exploiter des données réelles afin d'identifier des tendances, des relations statistiques et des facteurs influençant la survenue et la gravité des accidents de la route. Le présent rapport ne porte pas sur le développement du projet en tant que tel, mais se concentre exclusivement sur les analyses statistiques réalisées, les visualisations produites et l'interprétation des résultats associés, avec une volonté claire de rendre ces résultats accessibles à un public non technique.

Les analyses reposent sur le dataset *US-Accidents*, un jeu de données de grande ampleur recensant plus de 7,7 millions d'accidents survenus dans 49 États des États-Unis entre février 2016 et mars 2023. Pour des raisons pédagogiques et de performance, une version échantillonnée d'environ 500 000 observations est utilisée dans cette étude. Le dataset comporte 46 variables décrivant différents aspects des accidents, notamment la gravité, la localisation géographique, les caractéristiques temporelles, les conditions météorologiques ainsi que la présence d'infrastructures et de dispositifs de signalisation routière. Les données proviennent de sources multiples, telles que les départements de transport, les forces de l'ordre, des capteurs routiers et des stations météorologiques, garantissant ainsi une richesse et une diversité d'informations propices à des analyses statistiques approfondies.

À travers ce rapport, l'objectif est donc de proposer une analyse structurée et interprétable des données d'accidents de la route, en mettant en évidence des insights pertinents et exploitables. Ces résultats visent à contribuer à une meilleure compréhension des facteurs de risque et à fournir des éléments d'aide à la décision pouvant être utiles aux acteurs impliqués dans la prévention et l'amélioration de la sécurité routière.

1

Description des jeux de données

Ce chapitre présente les jeux de données utilisés dans le cadre de cette étude. Il distingue le dataset original *US-Accidents*, tel qu'il est fourni par les sources officielles, et le dataset échantillonné qui a été utilisé pour réaliser les analyses statistiques avancées. Cette distinction est importante afin de comprendre les choix méthodologiques effectués et les contraintes liées au volume des données.

1.1 Dataset original US-Accidents

Le dataset original *US-Accidents* constitue l'une des bases de données publiques les plus complètes sur les accidents de la route aux États-Unis. Il recense plus de 7,7 millions d'accidents survenus dans 49 États, sur une période allant de février 2016 à mars 2023. La taille du fichier principal est d'environ 3,06 Go, ce qui en fait un jeu de données volumineux nécessitant des ressources matérielles et logicielles adaptées pour son exploitation complète.

Ce jeu de données est constitué de 46 variables décrivant différents aspects des accidents. Ces variables couvrent notamment la gravité de l'accident, la localisation géographique, les informations temporelles, les conditions météorologiques ainsi que la présence d'infrastructures routières et de dispositifs de signalisation. Les données ont été collectées à partir de plusieurs sources, incluant les départements de transport, les forces de l'ordre, des caméras de surveillance routière et des capteurs, puis enrichies par des données météorologiques issues de stations locales.

1.2 Description des variables

Le dataset *US-Accidents* est composé de 46 variables décrivant de manière détaillée les caractéristiques des accidents de la route. Ces variables peuvent être regroupées en plusieurs catégories selon la nature des informations qu'elles fournissent.

1.2.1 Identification et gravité de l'accident

- **ID** : Identifiant unique de l'accident.
- **Source** : Source de collecte des données.

- **Severity** : Niveau de gravité de l'accident, codé de 1 (impact faible) à 4 (impact très élevé sur le trafic).

1.2.2 Informations temporelles

Nom de la variable	Description
Start_Time	Date et heure de début de l'accident.
End_Time	Date et heure de fin de l'incident.
Timezone	Fuseau horaire local associé au lieu de l'accident.
Sunrise_Sunset	Indique si l'accident s'est produit de jour ou de nuit.
Civil_Twilight	Indique si l'accident s'est produit durant le crépuscule civil.
Nautical_Twilight	Indique si l'accident s'est produit durant le crépuscule nautique.
Astronomical_Twilight	Indique si l'accident s'est produit durant le crépuscule astronomique.

TABLE 1.1 – Description des variables temporelles du dataset

1.2.3 Localisation géographique

Nom de la variable	Description
Start_Lat, Start_Lng	Coordonnées GPS du point de départ de l'accident.
End_Lat, End_Lng	Coordonnées GPS du point de fin de l'incident.
Street	Nom de la rue où l'accident s'est produit.
City	Ville où l'accident a eu lieu.
County	Comté correspondant à l'emplacement de l'accident.
State	État américain concerné.
Zipcode	Code postal de localisation.
Country	Pays (toujours États-Unis).

TABLE 1.2 – Description des variables de localisation géographique du dataset

1.2.4 Conditions météorologiques

Nom de la variable	Description
Weather_Timestamp	Horodatage de l'observation météorologique.
Temperature(F)	Température en degrés Fahrenheit.
Wind_Chill(F)	Température ressentie.
Humidity(%)	Taux d'humidité.
Pressure(in)	Pression atmosphérique.
Visibility(mi)	Distance de visibilité.
Wind_Direction	Direction du vent.
Wind_Speed(mph)	Vitesse du vent.
Precipitation(in)	Niveau de précipitations.
Weather_Condition	Conditions météorologiques observées.

TABLE 1.3 – Description des variables météorologiques du dataset

1.2.5 Infrastructures routières et signalisation

Nom de la variable	Description
Amenity	Présence d'une aménité à proximité (ex : restaurant, station essence, parking).
Bump	Présence d'un ralentisseur ou dos d'âne.
Crossing	Présence d'un passage piéton à proximité.
Give_Way	Présence d'un panneau cédez-le-passage.
Junction	Présence d'une jonction ou intersection avec d'autres routes.
No_Exit	Présence d'une impasse ou route sans issue.
Railway	Présence d'une voie ferrée proche de l'accident.
Roundabout	Présence d'un rond-point.
Station	Présence d'une station de transport (bus, train).
Stop	Présence d'un panneau stop.
Traffic_Calming	Dispositifs de ralentissement du trafic (chicanes, rétrécissements).
Traffic_Signal	Présence d'un feu de signalisation.
Turning_Loop	Présence d'une boucle de virage pour véhicules.

TABLE 1.4 – Description des variables d'infrastructures routières et signalisation du dataset

1.3 Traitements préalables des données

L'étude a commencé par une Analyse Exploratoire des Données (EDA). Ce travail a servi à comprendre comment le fichier est construit, à lister les types de variables (numériques, catégorielles, temporelles) et à voir toutes les informations utiles sur les accidents.

Dans cette EDA, faire des statistiques descriptives a été une étape clé. En calculant les moyennes, les médianes et l'écart-type, ainsi que la fréquence et la distribution des catégories, nous avons pu voir les grandes tendances. Ces chiffres nous ont aidés à repérer les erreurs et à choisir la suite de l'analyse.

Suite à ces premières observations, un rigoureux processus de nettoyage des données a été mis en œuvre :

- **Gestion des valeurs manquantes** : Identification et traitement des données non renseignées.
- **Harmonisation catégorielle** : Regroupement de modalités complexes, par exemple pour simplifier les variables météorologiques en catégories plus lisibles.
- **Vérification de la cohérence** : Rectification des formats temporels et traitement des valeurs aberrantes (outliers) susceptibles de fausser les interprétations.

Enfin, bien que le volume massif du dataset original soit un atout pour la précision, il représentait une contrainte majeure en termes de temps de calcul et de ressources pour les visualisations complexes. C'est pourquoi, après avoir garanti la qualité des données par le nettoyage et l'exploration, nous avons procédé à un échantillonnage représentatif.

La figure 1.1 ci-dessous présente le processus de préparation des données.




FIGURE 1.1 – Processus de Préparation des Données

1.4 Dataset échantillonné utilisé pour les analyses

Pour travailler plus efficacement, nous avons extrait un échantillon de 769 344 observations du dataset original. Nous avons utilisé un **échantillonnage stratifié par État et par mois** : cette méthode est essentielle pour garantir que toutes les régions et toutes les saisons soient représentées de manière équitable dans nos calculs.

L'utilisation de cet échantillon permet de réduire les temps de calcul tout en gardant une base de données assez large pour appliquer de la **statistique inférentielle** (analyses de variance, corrélation, régressions et autres). Ces méthodes nous permettent de tirer des conclusions qui restent valides pour l'ensemble du dataset original.

Toutes les analyses et visualisations présentées dans ce rapport s'appuient sur cet échantillon. Grâce à la rigueur de notre méthode de sélection, les tendances et les résultats obtenus sont représentatifs de la réalité globale des accidents aux *États-Unis*. Ce choix assure donc un équilibre idéal entre la précision scientifique et la rapidité d'exécution technique.

2

Visualisations et Interprétations

Dans ce chapitre, nous analysons la gravité des accidents de la route à travers plusieurs axes complémentaires, en nous appuyant sur des visualisations de données et leurs interprétations.

L'analyse repose sur quatre dimensions : l'analyse temporelle, qui met en évidence les périodes critiques ; l'analyse météorologique, qui évalue l'impact des conditions climatiques ; l'analyse infrastructurelle, qui examine le rôle des équipements routiers et des zones à risque ; et l'analyse géographique, qui explore les disparités spatiales des accidents.

2.1 Condition météo et environnement

2.1.1 Sévérité des accidents selon la météo

Cette analyse est faite à l'aide d'un diagramme à barres empilées à 100%, il permet d'analyser les proportions relatives de chaque niveau de sévérité pour chaque condition météo.

Voici l'analyse détaillée de ce que nous montre ce graphique :

Structure du graphique :

Barres (axe des abscisses) : chaque barre représente une catégorie météorologique. Elles font toutes la même hauteur car elles représentent 100% des accidents enregistrés pour cette catégorie spécifique.

Couleurs (légende) : Les segments colorés indiquent le niveau de sévérité, du plus faible (1, violet foncé) au plus élevé (4, jaune vif).

Axe des ordonnées : Il représente la part relative de chaque niveau de sévérité au sein d'une même condition météorologique.

Observations clés :

Prédominance de la sévérité de niveau 2 : On voit clairement que dans toutes les conditions météo, le niveau 2 est ultra-majoritaire (environ 75% à 85% des cas).

Sévérité 4 (Jaune) : Les accidents les plus graves semblent proportionnellement plus présents lors des conditions "Cloudy" (Nuageux), "Rain" (Pluie) et "Snow" (Neige) par rapport aux autres catégories.

Précipitations hivernales (Wintry precipitation) : On remarque l'absence presque totale de sévérité 1 et 4. Les accidents y sont soit de niveau 2, soit de niveau 3.

Interprétation

La relative stabilité de la sévérité, dominée par le niveau 2, suggère que la gravité des accidents dépend potentiellement moins des conditions météorologiques elles-mêmes que d'autres facteurs tels que la vitesse, l'état des infrastructures ou le comportement des conducteurs, notamment leur capacité d'adaptation face aux conditions de circulation.

La figure 2.12 ci-dessous présente le diagramme à barres empilées à 100% :




FIGURE 2.1 – Proportions de sévérité par météo (Bar Chart Empilé à 100%)

2.1.2 Visibilité vs Sévérité

Ce nouveau graphique est un nuage de points (*Scatter Plot*) visant à analyser la relation entre la visibilité (exprimée en milles) et la sévérité des accidents.

Structure du graphique :

La ligne de régression (graphique avec trait rouge) : La ligne de régression apparaît quasiment horizontale.

La densité des points (nuage de points) : La concentration des points est particulièrement élevée dans l'intervalle compris entre 0 et 10 milles sur l'axe de la visibilité.

Le diagramme à barres empilées (rappel de la météo) : Ce graphique complémentaire illustre la répartition des niveaux de sévérité selon les conditions météorologiques.

Observations clés :

La quasi-horizontalité de la ligne de régression indique l'absence d'une corrélation linéaire marquée entre la visibilité et la sévérité des accidents. Autrement dit, une diminution de la visibilité n'entraîne pas systématiquement une augmentation de la gravité moyenne des accidents.

On observe néanmoins des accidents de sévérité élevée, y compris dans des conditions de visibilité optimale (jusqu'à 100 mi), ce qui suggère l'influence de facteurs supplémentaires tels que la vitesse, le type de route ou le comportement du conducteur.

Par ailleurs, la forte densité des points pour les faibles valeurs de visibilité confirme que le nombre d'accidents augmente significativement lorsque la visibilité diminue, même si la répartition des niveaux de gravité reste globalement stable.

Interprétation :

Ces résultats suggèrent que la visibilité influence davantage la fréquence des accidents que leur gravité. La sévérité semble dépendre principalement d'autres variables structurelles et comportementales, tandis que la baisse de visibilité agit surtout comme un facteur déclencheur augmentant le risque d'occurrence des accidents.

La figure 2.2 ci-dessous présente le nuage de points correspondant à cette analyse.




FIGURE 2.2 – Lien Visibilité / Sévérité (Scatter Plot)

2.1.3 Variables météorologiques et la sévérité des accidents

Cette matrice de corrélation de Spearman constitue un outil quantitatif permettant de confirmer les observations issues des visualisations précédentes. Elle mesure la force et le sens des relations entre les variables météorologiques et la sévérité des accidents.

Structure du graphique :

La matrice présente les coefficients de corrélation de Spearman entre les différentes variables météorologiques (température, humidité, visibilité, précipitations, vitesse du vent) ainsi que la variable de sévérité. Les valeurs sont comprises entre -1 et 1 , où une valeur proche de 0 indique l'absence de relation monotone significative.

Observations clés :

Isolement de la variable Sévérité : La première ligne correspondant à la sévérité montre des coefficients très proches de zéro, compris approximativement entre -0.01 et 0.04 . Cela indique l'absence d'une corrélation statistique notable entre la gravité des accidents et chacune des variables météorologiques prises individuellement.

Relations entre variables météorologiques : La matrice met en évidence des dépendances marquées entre certaines variables climatiques :

- **Visibilité et humidité :** une corrélation négative relativement forte est observée, indiquant qu'une augmentation de l'humidité est associée à une diminution de la visibilité, phénomène cohérent avec la présence de brouillard ou de précipitations.
- **Visibilité et précipitations :** une corrélation négative significative confirme que l'intensification des précipitations s'accompagne d'une baisse de la visibilité.
- **Température et humidité :** la corrélation négative observée suggère qu'une hausse de la température est généralement associée à une baisse de l'humidité relative.

Interprétation :

Cette matrice de corrélation apporte une validation statistique aux analyses visuelles réalisées précédemment. Elle permet de distinguer clairement deux effets distincts de la météo sur les accidents de la route.

D'une part, la météo apparaît comme un facteur peu pertinent pour prédire la gravité des accidents, celle-ci semblant davantage influencée par des éléments tels que la vitesse d'impact, le type de véhicule, l'infrastructure routière ou le comportement du conducteur.

D'autre part, l'absence de corrélation entre la visibilité et la sévérité n'entre pas en contradiction avec l'observation d'un nombre plus élevé d'accidents lorsque la visibilité est faible. Cela indique que, quelle que soit la condition météorologique, la répartition relative des niveaux de gravité reste globalement stable.

En résumé, les conditions météorologiques influencent principalement la fréquence des accidents, mais n'ont qu'un impact limité sur leur dangerosité relative.

La figure 2.3 ci-dessous présente la matrice de corrélation correspondant à cette analyse.




FIGURE 2.3 – Corrélations Variables Météo

2.1.4 Nombre d'accidents par condition météo

Ce dernier graphique, sous forme de diagramme en barres, complète l'analyse en présentant le volume absolu d'accidents, c'est-à-dire le nombre total d'événements recensés pour chaque condition météorologique.

Structure du graphique :

Le diagramme représente, pour chaque catégorie météorologique, le nombre total d'accidents observés sur l'ensemble de la période étudiée. Contrairement aux visualisations précédentes, ce graphique ne s'appuie pas sur des proportions ou des distributions, mais sur des valeurs absolues, ce qui permet d'appréhender la fréquence réelle des accidents selon la météo.

Observations clés :

Prédominance des conditions météorologiques normales : Le nombre d'accidents est maximal lors des conditions *Clear* (dégagé), avec environ 350 000 accidents, suivi par la catégorie *Cloudy* (nuageux) qui dépasse les 300 000 occurrences. Cette observation s'explique par le fait que ces conditions sont les plus fréquentes au cours de l'année et correspondent à des périodes de trafic plus dense.

Interprétation trompeuse des conditions extrêmes : À première vue, des conditions telles que le brouillard (*Fog*) ou la neige (*Snow*) semblent associées à un nombre réduit d'accidents, inférieur à 25 000. Toutefois, ce graphique reflète uniquement la fréquence des accidents et non le niveau de risque. Les conditions de faible visibilité ou les phénomènes météorologiques extrêmes sont relativement rares, ce qui limite mécaniquement le nombre total d'accidents observés.

Pour évaluer le risque réel, il serait nécessaire de rapporter ces volumes au nombre total d'heures pendant lesquelles ces conditions se produisent.

Interprétation :

Ce graphique permet de mieux comprendre les résultats obtenus dans les analyses précédentes. La forte concentration de points observée dans le nuage de points pour des visibilités élevées correspond directement à la domination des conditions *Clear* et *Cloudy* dans les statistiques globales.

De même, la stabilité de la sévérité moyenne autour du niveau 2 s'explique par la prédominance d'accidents survenant dans des conditions météorologiques normales. Ces accidents, très nombreux, masquent statistiquement les cas plus rares associés à des conditions extrêmes.

La figure 2.4 ci-dessous présente le diagramme en barres correspondant à cette analyse.




FIGURE 2.4 – Nombre d'accidents par météo (Bar Chart)

2.2 Analyse spatiale et risque géographique

2.2.1 Gravité des accidents par région

Le graphique présente la distribution de la gravité des accidents (*Severity*, échelle de 1 à 4) selon les quatre grandes régions des États-Unis, à l'aide d'un boxplot.

Structure du graphique :

Chaque boîte représente la dispersion des niveaux de gravité pour une région donnée.

La médiane (ligne horizontale à l'intérieur de la boîte) indique le niveau de gravité central des accidents.

Le premier et le troisième quartile (bornes inférieure et supérieure de la boîte) délimitent l'intervalle dans lequel se situent 50 % des observations.

Les moustaches (*whiskers*) représentent l'étendue des valeurs non extrêmes et traduisent la variabilité globale.

Les valeurs aberrantes (*outliers*) apparaissent sous forme de points isolés et correspondent aux accidents de gravité exceptionnelle.

Observations clés :

Médiane identique (2.0) : Toutes les régions présentent une médiane de gravité égale à 2, indiquant que la majorité des accidents sont de gravité modérée, ni très légers (niveau 1), ni extrêmement graves (niveau 4).

Région Midwest : variabilité la plus élevée : La boîte associée au Midwest est nettement plus large, traduisant une dispersion importante entre le premier et le troisième quartile. Les moustaches s'étendent des niveaux 1 à 4, ce qui révèle la coexistence d'accidents très légers et très graves. De plus, la présence de nombreux points aberrants au niveau 4 souligne une fréquence relativement élevée d'accidents très graves.

Régions Northeast, South et West : distributions plus compactes : Ces régions présentent des boîtes plus étroites, indiquant une faible variation de la gravité des accidents. Les moustaches sont relativement courtes, traduisant une présence limitée d'événements extrêmes. Quelques valeurs aberrantes de gravité 4 sont néanmoins observées, principalement dans les régions South et West, mais en quantité inférieure à celle du Midwest.

Interprétation :

La région Midwest se distingue par une distribution de la gravité des accidents significativement plus dispersée que celles des autres régions. Cette variabilité suggère la coexistence de contextes de circulation très différents, allant d'accidents mineurs à des accidents particulièrement graves.

Cette hétérogénéité peut s'expliquer par des facteurs locaux tels que la prédominance de routes rurales à grande vitesse, des conditions météorologiques hivernales plus sévères et une densité de trafic variable selon les zones traversées.

La figure 2.5 ci-dessous présente la boîte à moustaches correspondant à cette analyse.




FIGURE 2.5 – Gravité par region (Box plot)

2.2.2 Répartition géographique des accidents

Ce graphique illustre la répartition géographique des accidents routiers aux États-Unis à partir des coordonnées GPS (`Start_Lat`, `Start_Lng`). Chaque point bleu correspond à un accident recensé dans l'échantillon étudié.

Structure du graphique :

La représentation repose sur un nuage de points géographiques superposés à la carte du territoire américain.

Chaque point symbolise un accident individuel localisé par ses coordonnées géographiques.

L'échelle spatiale permet d'observer à la fois les concentrations régionales et la dispersion des accidents à l'échelle nationale.

Observations clés :

Forte concentration le long des axes urbains et routiers : Les points sont particulièrement denses le long des côtes Est et Ouest, notamment à proximité des grands corridors autoroutiers tels que l'I-95 et l'I-5, ainsi que dans plusieurs métropoles intérieures comme Chicago, Dallas ou Atlanta. Cette concentration confirme que les accidents surviennent majoritairement dans les zones à fort trafic, incluant les centres urbains, les autoroutes et les zones commerciales.

Faible densité dans les zones rurales et désertiques : Le centre du pays, incluant des États comme le Wyoming, le Montana ou le Nevada, présente une densité de points nettement plus faible. Cette observation reflète une population réduite et un trafic routier limité dans ces régions.

Cohérence géographique des données : La forme générale du territoire est fidèlement reproduite, ce qui valide la qualité des données de localisation et indique l'absence d'erreurs majeures dans les coordonnées géographiques.

Absence de points hors du territoire étudié : Aucun accident n'est localisé en dehors du territoire continental, ce qui confirme que les données ont été correctement filtrées pour ne concerner que les 49 États couverts par l'étude.

Interprétation :

La distribution spatiale des accidents routiers apparaît fortement corrélée à la densité de population et à la structuration du réseau routier. Les zones les plus touchées correspondent aux régions où le trafic est le plus intense, notamment les grandes agglomérations, les axes autoroutiers inter-États et les régions métropolitaines majeures.

La figure 2.7 ci-dessous présente le nuage de points géographique correspondant à cette analyse.




FIGURE 2.6 – Répartition géographique(Scatter plot)

2.2.3 Gravité des accidents – Urbain vs Rural

Ce graphique compare la distribution de la gravité des accidents (*Severity*, échelle 1–4) entre les zones urbaines et rurales, à l’aide d’un boxplot. Chaque boîte représente la dispersion des niveaux de gravité pour un type de zone.

Structure du graphique :

Chaque boîte illustre la distribution des accidents pour le type de zone correspondant.

Médiane : Ligne horizontale à l’intérieur de la boîte, indiquant le niveau de gravité central.

Premier et troisième quartile : Bornes de la boîte, représentant l’intervalle médian contenant 50 % des observations.

Whiskers : Lignes s’étendant au-delà de la boîte, montrant l’étendue des valeurs non extrêmes.

Valeurs aberrantes (*outliers*) : Points isolés représentant les accidents exceptionnels, notamment les plus graves.

Observations clés :

Médiane identique (2.0) : Les zones urbaines et rurales présentent la même médiane de gravité, indiquant que la majorité des accidents sont modérés, ni très légers (1), ni très graves (4).

Zone rurale : variabilité plus élevée : La boîte est légèrement plus large que celle de la zone urbaine, montrant une dispersion un peu plus importante des niveaux de gravité. Le whisker supérieur atteint 3.0, reflétant la présence d'accidents plus graves, et un outlier au niveau 4 indique un accident exceptionnellement grave.

Zone urbaine : distribution plus compacte : La boîte est étroite, traduisant une faible variation dans la gravité des accidents. Les whiskers sont courts, et quelques outliers de gravité 4 apparaissent, mais en nombre inférieur à la zone rurale.

Interprétation :

Les accidents survenus en zone rurale tendent à présenter une gravité légèrement supérieure et plus variable que ceux en zone urbaine. Bien que la médiane soit identique, la présence d'outliers de niveau 4 et la dispersion plus large suggèrent que les routes rurales, souvent plus rapides et moins surveillées, conduisent à des accidents plus graves lorsqu'ils se produisent.

Insight actionnable :

Malgré un volume total d'accidents inférieur, les zones rurales devraient être priorisées dans les politiques de sécurité routière. Des mesures telles que la limitation de vitesse, l'amélioration de la signalisation et le renforcement des services d'urgence pourraient contribuer à réduire la gravité des accidents dans ces zones.

La figure 2.7 ci-dessous présente la boîte à moustaches correspondant à cette analyse.




FIGURE 2.7 – Gravité : Urbain vs Rural (Box plot)

2.2.4 Densité des accidents vs Gravité moyenne par État

Ce graphique en nuage de points compare, pour chaque État, le nombre total d'accidents (axe horizontal) et la gravité moyenne des accidents (axe vertical). Chaque point représente un État.

Structure du graphique :

Chaque point symbolise un État.

Axe horizontal : nombre total d'accidents par État.

Axe vertical : gravité moyenne des accidents pour cet État.

Le nuage de points permet d'évaluer visuellement la relation entre le volume d'accidents et leur gravité moyenne.

Observations clés :

Absence de corrélation claire : Les points sont dispersés sans tendance nette. Certains États avec un grand nombre d'accidents présentent une gravité moyenne relativement faible, tandis que d'autres États avec peu d'accidents affichent une gravité plus élevée. Cela indique qu'un volume élevé d'accidents ne se traduit pas nécessairement par des accidents plus graves.

États à forte densité d'accidents : Des exemples tels que Californie (CA), Texas (TX) ou Floride (FL) se situent à droite du graphique (beaucoup d'accidents) mais présentent

une gravité moyenne modérée (environ 2.1–2.3). Cela suggère que dans ces grands États, les accidents sont fréquents mais généralement moins graves, probablement grâce à de meilleures infrastructures et à une circulation plus contrôlée.

États à faible densité d'accidents : Certains États comme le Wyoming (WY), le Vermont (VT) ou le Delaware (DE) présentent un nombre réduit d'accidents, mais une gravité moyenne plus élevée (jusqu'à 2.5). Cette observation indique que dans les zones moins peuplées, les accidents sont plus rares mais souvent plus graves, en raison de vitesses plus élevées, de routes moins sécurisées et de délais d'intervention plus longs.

Points isolés : Un État à très forte densité (ex. CA) a une gravité moyenne très faible (2.1), tandis qu'un État à faible densité peut présenter une gravité très élevée (2.5), confirmant que la fréquence des accidents n'implique pas la gravité.

Interprétation :

Il n'existe pas de lien linéaire entre le nombre total d'accidents et leur gravité moyenne par État. Les États à fort trafic enregistrent souvent des accidents fréquents mais moins graves, alors que les États à faible trafic peuvent connaître des accidents rares mais plus sévères.

Insight actionnable :

La sécurité routière ne peut pas être évaluée uniquement par le nombre d'accidents. Les États à faible densité, bien que moins touchés en volume, devraient être prioritaires pour des interventions ciblées sur la gravité des accidents : amélioration des routes, limitation de vitesse et renforcement des services d'urgence.

La figure 2.8 ci-dessous présente le nuage de points correspondant à cette analyse.




FIGURE 2.8 – Densité vs gravité par état (Scatter plot)

2.2.5 Niveau de risque par région

Ce graphique en barres empilées présente la répartition des États selon leur niveau de risque (*Low Risk* et *Medium Risk*) par grande région des États-Unis. Chaque barre correspond à une région, tandis que les segments colorés indiquent le nombre d'États appartenant à chaque catégorie de risque.

Structure du graphique :

Chaque barre représente une région géographique. **Segments colorés** : ils indiquent le nombre d'États classés dans chaque niveau de risque.

La hauteur totale d'une barre correspond au nombre total d'États composant la région.

Observations clés :

Région Sud : prédominance du risque moyen : La barre associée à la région Sud est presque entièrement constituée d'États classés en *Medium Risk*. Cette domination confirme que cette région, déjà identifiée comme celle présentant le plus fort volume d'accidents, affiche également un profil de risque global élevé.

Région Ouest : profil mixte : La région West présente une majorité d'États en risque moyen, accompagnée d'une part non négligeable d'États en faible risque. Cette configuration traduit une forte hétérogénéité interne : certains États, comme la Californie, connaissent un grand nombre d'accidents mais de gravité modérée, tandis que d'autres peuvent présenter moins d'accidents mais une gravité plus élevée.

Région Midwest : dominance du faible risque : La barre du Midwest est majoritairement composée d'États classés en *Low Risk*. Ce résultat apparaît cohérent avec un risque global limité, malgré la variabilité de gravité observée précédemment. Il suggère que l'indicateur de risque utilisé repose davantage sur la fréquence des accidents que sur leur gravité.

Région Northeast : profil intermédiaire : La région Northeast présente une répartition relativement équilibrée entre les deux niveaux de risque. Ce positionnement intermédiaire peut s'expliquer par une forte densité urbaine combinée à des infrastructures routières généralement mieux structurées.

Interprétation :

La région Sud se distingue comme la zone présentant le niveau de risque global le plus élevé, avec la quasi-totalité de ses États classés en risque moyen. À l'inverse, le Midwest apparaît majoritairement en faible risque, bien qu'il présente une forte hétérogénéité en termes de gravité des accidents. Cette divergence souligne que la mesure du risque retenue privilégie principalement la fréquence des accidents plutôt que leur sévérité.

Insight actionnable :

La région Sud devrait constituer une priorité pour les politiques de sécurité routière. Son niveau de risque élevé, combiné à une forte densité d'accidents, en fait une zone critique

nécessitant des interventions ciblées. Par ailleurs, le Midwest, bien que classé globalement en *Low Risk*, mérite une analyse plus fine afin d'identifier les zones locales à très haut risque, susceptibles d'être masquées par les indicateurs globaux.

La figure 2.9 ci-dessous présente le graphique en barres empilées correspondant à cette analyse.




FIGURE 2.9 – Niveau de risque par région (barres empilées)

2.2.6 Top 10 États par nombre d'accidents

Ce graphique en barres présente les dix États ayant enregistré le plus grand nombre d'accidents dans l'échantillon étudié. Il permet d'identifier les zones géographiques où la fréquence des accidents routiers est la plus élevée.

Observations clés :

Californie (CA) en tête : La Californie domine largement le classement avec près de 175 000 accidents. Cette position s'explique par une population très élevée, un réseau routier dense et des conditions climatiques favorables à la circulation tout au long de l'année.

Floride (FL) et Texas (TX) aux deuxième et troisième rangs : La Floride enregistre environ 90 000 accidents, en partie liés à une forte densité touristique et résidentielle. Le Texas, avec près de 60 000 accidents, se distingue par son vaste territoire et un trafic intense sur les autoroutes inter-États.

Hierarchie décroissante marquée : Les États suivants (SC, NY, NC, VA, PA, MN et OR) comptabilisent entre 20 000 et 40 000 accidents, soit un volume nettement inférieur à celui observé en Californie, en Floride et au Texas. Cette différence met en évidence une forte concentration des accidents dans un nombre limité d'États.

Absence des États faiblement peuplés : Aucun État à faible population, tels que le Vermont ou le Wyoming, n'apparaît dans le classement, ce qui reflète logiquement un trafic routier plus réduit et donc un nombre d'accidents moindre.

Interprétation :

La Californie, la Floride et le Texas concentrent une part significative des accidents routiers aux États-Unis. Cette dominance est principalement liée à des facteurs structurels tels que la population, la superficie et le volume de trafic, plutôt qu'à un niveau de risque intrinsèquement plus élevé par conducteur.

La figure 2.10 ci-dessous présente le graphique à barres correspondant à cette analyse.




FIGURE 2.10 – Top 10 états par nombre d'accidents (Barre Chart)

2.2.7 Répartition des accidents par région

Ce diagramme circulaire illustre la répartition des accidents routiers par grande région aux États-Unis. Chaque segment représente la part relative du nombre total d'accidents attribuée à une région géographique.

Structure du graphique :

Chaque portion du diagramme correspond à une région (South, West, Northeast, Midwest), exprimée en pourcentage du total des accidents observés.

Cette représentation permet d'évaluer le poids relatif de chaque région dans la sinistralité routière nationale.

Observations principales :

Région South dominante : La région South concentre 39,9 % des accidents, ce qui en fait la zone la plus touchée à l'échelle nationale. Près de quatre accidents sur dix recensés dans l'échantillon s'y produisent, traduisant un poids particulièrement élevé en matière de sécurité routière.

Région West en deuxième position : Avec 37,6 % des accidents, la région West se situe juste derrière le South. À elles deux, ces régions regroupent plus de 75 % du total des accidents, ce qui les identifie comme les principales zones à risque du territoire américain.

Région Northeast : niveau intermédiaire : La région Northeast représente 14,4 % des accidents. Malgré une forte densité urbaine et un trafic important, son volume d'accidents demeure significativement inférieur à celui des régions South et West, suggérant une meilleure maîtrise des facteurs de risque.

Région Midwest : contribution la plus faible : Avec seulement 8,2 % des accidents, le Midwest apparaît comme la région la moins affectée en termes de volume. Bien que la gravité des accidents puisse y être variable, leur fréquence globale reste limitée.

La figure 2.11 ci-dessous présente le graphique en secteurs correspondant à cette analyse.




FIGURE 2.11 – Répartition des accidents par région (Pie Chart)

2.3 Infrastructure routière et sécurité

2.3.1 Sévérité des accidents selon le niveau de protection

Le graphique présente la distribution de la gravité des accidents (*Severity*, sur une échelle de 1 à 4) en fonction de quatre niveaux de protection des infrastructures routières : Unprotected, Poorly_Protected, Moderately_Protected et Well_Protected. La visualisation est réalisée à l'aide d'un diagramme en violon violin plot).

Voici l'analyse détaillée de ce que nous montre ce graphique :

Structure du graphique :

La forme du violon : Elle représente la densité de probabilité des données. Plus le violon est large à un niveau donné, plus la fréquence des accidents de cette gravité est élevée.

La ligne centrale (en pointillés) : Elle indique la médiane, soit le niveau de gravité central pour chaque catégorie de protection.

Les pointes (extrémités) : Elles montrent l'étendue des données, incluant les valeurs les plus faibles (1) et les plus élevées (4).

La largeur horizontale : Elle permet de visualiser la concentration des observations autour de certaines valeurs de gravité.

Observations clés :

Médiane constante (2.0) : Pour les trois premières catégories (Unprotected, Moderately_Protected et Poorly_Protected), la médiane se situe systématiquement au niveau 2. Cela indique que, quel que soit le niveau de protection (sauf pour le niveau "Well_Protected"), la majorité des accidents reste d'une gravité modérée.

Similitude des profils Unprotected et Poorly_Protected : La catégorie "Extreme" se distingue nettement. Elle possède une part de sévérité 2 beaucoup plus importante (environ 90%) et une part de sévérité 3 (vert) beaucoup plus réduite que les autres. Étonnamment, la part de sévérité 4 (jaune) y semble très faible.

Cas particulier "Well_Protected" : Les accidents les plus graves semblent proportionnellement plus présents lors des conditions "Cloudy" (Nuageux), "Rain" (Pluie) et "Snow" (Neige) par rapport aux autres catégories.

Variabilité décroissante : On remarque l'absence presque totale de sévérité 1 et 4. Les accidents y sont soit de niveau 2, soit de niveau 3.

Interprétation

La relative stabilité de la sévérité, dominée par le niveau 2, suggère que la gravité des accidents dépend potentiellement moins des conditions météorologiques elles-mêmes que d'autres facteurs tels que la vitesse, l'état des infrastructures ou le comportement des conducteurs, notamment leur capacité d'adaptation face aux conditions de circulation.

La figure 2.12 ci-dessous présente le diagramme à barres empilées à 100% :




FIGURE 2.12 – Impact du niveau de protection sur la variabilité et l'intensité de la gravité (Violin plot)

2.3.2 Sévérité des accidents selon le niveau de risque

Le graphique présente la distribution de la gravité des accidents (Severity, échelle de 1 à 4) en fonction du niveau de risque lié à l'infrastructure (Medium, Very_Low, Very_High, High, Low), à l'aide d'une boîte à moustaches (boxplot).

Structure du graphique :

- Chaque boîte représente la dispersion des niveaux de gravité pour une catégorie de risque spécifique.
- La ligne horizontale noire (médiane) indique la tendance centrale de la gravité.
- Pour la catégorie *Very_High*, le rectangle vert délimite l'écart interquartile (50 % des données).
- Les points isolés (diamants noirs) représentent les valeurs aberrantes (*outliers*), correspondant à des accidents de gravité inhabituelle pour la catégorie concernée.

Observations clés :

- **Médiane uniforme (2.0) :** Toutes les catégories de risque présentent une médiane de gravité égale à 2. Cela indique que, statistiquement, l'accident "type" reste de gravité modérée, quel que soit le niveau de risque infrastructurel.
- **Risque "Very_High" : dispersion maximale :** Contrairement aux autres catégories, le niveau *Very_High* présente une boîte très étendue. Le troisième quartile

atteint le niveau 3 et la moustache supérieure s'étire jusqu'au niveau 4. Cela démontre une variabilité beaucoup plus forte et une probabilité accrue d'accidents graves.

- **Profils concentrés (Medium, High, Low, Very_Low) :** Pour ces quatre catégories, la boîte est "écrasée" sur la médiane (2). La quasi-totalité des accidents se concentre sur ce niveau. Les gravités 1, 3 et 4 n'apparaissent que sous forme de valeurs aberrantes, ce qui signifie qu'elles sont statistiquement rares.

Interprétation : L'analyse montre que le risque infrastructurel n'influence pas la gravité médiane, mais impacte significativement la **fréquence des accidents sévères**. Lorsque le risque est jugé "Very_High", la structure même de la distribution change : la gravité n'est plus confinée au niveau 2, mais s'étale largement vers les niveaux supérieurs.

Cette observation suggère que dans les zones à très haut risque (virages dangereux, intersections complexes, manque de signalisation), les circonstances de l'accident sont plus imprévisibles et mènent plus fréquemment à des conséquences lourdes. Pour les autres niveaux de risque, l'infrastructure semble mieux "canaliser" la gravité, les accidents graves y restant des exceptions isolées.




FIGURE 2.13 – Distribution de la gravité selon le niveau de risque infrastructurel (Box plot)

2.3.3 Gravité normalisée par type d'intersection :

Le graphique ci-après illustre la distribution de la gravité des accidents (échelle de 1 à 4) selon la configuration de l'intersection, sous la forme d'une **carte de chaleur (heatmap)** normalisée.

Structure du graphique :

- **L'axe vertical :** Répertorie les différents types d'aménagements (rond-point, carrefour à stop, intersection signalisée, etc.).

- **L'axe horizontal** : Représente les quatre niveaux de gravité.
- **L'échelle de couleur** : L'intensité du rouge indique la proportion d'accidents pour chaque niveau de gravité au sein d'une catégorie donnée. Les valeurs numériques (de 0.00 à 1.00) précisent cette proportion.

Observations clés :

- **Prédominance de la gravité 2** : Toutes les intersections affichent une concentration massive au niveau de gravité 2. Le cas le plus extrême est le *Roundabout_Junction* (rond-point), où 100 % des accidents enregistrés sont de gravité 2.
- **Intersections signalisées et danger relatif** : La catégorie *Signalized_Junction* présente la proportion la plus élevée d'accidents de gravité 3 (0.30) par rapport aux autres configurations. Bien que la majorité reste au niveau 2 (0.68), cette catégorie semble plus exposée à des chocs d'intensité supérieure.
- **Faible occurrence des extrêmes** : Les gravités 1 et 4 sont marginales pour l'ensemble des types d'intersections, avec des proportions ne dépassant jamais 0.04 (4 %).
- **Intersections non contrôlées** : Les *Uncontrolled_Junction* montrent une dispersion notable vers la gravité 3 (0.23), suggérant qu'en l'absence de signalisation, les accidents tendent à être légèrement plus sévères qu'au niveau des ronds-points ou des stops.

Interprétation : L'analyse montre que la configuration de l'intersection influence la répartition de la sévérité des collisions. Le **rond-point** apparaît comme l'aménagement le plus "sécurisant" au sens où il standardise la gravité à un niveau modéré, éliminant totalement les accidents très légers ou graves dans cet échantillon. Cela s'explique souvent par la réduction de la vitesse imposée par la géométrie circulaire.

À l'inverse, les **intersections signalisées** (*Signalized_Junction*), bien que contrôlées, affichent une part plus importante d'accidents de gravité 3. Cela peut traduire des collisions à des vitesses plus élevées (chocs latéraux ou non-respect de feu rouge) malgré la présence de signalisation. Globalement, la rareté du niveau 4 sur l'ensemble du graphique suggère que les intersections, par nature, limitent les vitesses d'impact par rapport aux sections de routes ouvertes.




FIGURE 2.14 – Distribution normalisée de la gravité selon le type d'intersection (Heatmap)

2.3.4 Gravité moyenne selon le niveau de sécurité/conflit :

Le graphique présente la gravité moyenne des accidents (Severity) en fonction de quatre niveaux de sécurité ou de conflit (*Balanced*, *No_Safety*, *Over_Protected*, *Under_Protected*), à l'aide d'un diagramme en barres (bar chart).

Structure du graphique :

- **L'axe horizontal** : Identifie les quatre classes de sécurité/conflit définies pour l'étude.
- **L'axe vertical** : Mesure le niveau de gravité moyen, s'étendant de 0.0 à 2.0+.
- **Les barres colorées** : La hauteur de chaque barre représente la valeur moyenne de la gravité pour chaque catégorie respective.

Observations clés :

- **Gravité maximale pour "No_Safety"** : La catégorie *No_Safety* affiche la gravité moyenne la plus élevée, dépassant légèrement le score de 2.2.
- **Niveaux de gravité similaires pour les autres catégories** : Les catégories *Balanced*, *Over_Protected* et *Under_Protected* présentent des gravités moyennes très proches, se situant toutes aux alentours de 2.1.
- **Faible amplitude de variation** : On observe une différence relativement faible entre la catégorie la moins grave (*Over_Protected*) et la plus grave (*No_Safety*), indiquant que le facteur de sécurité/conflit influence la gravité de manière subtile mais réelle.

Interprétation : L'analyse met en évidence que l'absence totale de mesures de sécurité (*No_Safety*) est directement corrélée à une augmentation de la sévérité moyenne des ac-

cidents. Cela confirme l'importance cruciale des dispositifs de gestion des conflits routiers pour limiter l'impact physique des collisions.

Il est intéressant de noter que le sur-équipement (*Over_Protected*) n'apporte pas une réduction drastique de la gravité par rapport à un état équilibré (*Balanced*). Cela suggère l'existence d'un "seuil d'efficacité" des infrastructures de sécurité : une fois qu'un niveau de protection adéquat est atteint, l'ajout de mesures supplémentaires n'influence plus de manière significative la gravité moyenne des accidents restants.




FIGURE 2.15 – Gravité moyenne selon le niveau de sécurité/conflit (Bar chart)

2.3.5 Relation entre l'indice de protection et la gravité

Le graphique illustre la corrélation entre l'indice de protection (variable continue) et la gravité des accidents (échelle de 1 à 4), à l'aide d'un **nuage de points** (*scatter plot*) complété par une **droite de régression linéaire**.

Structure du graphique :

- **L'axe horizontal** : Représente l'indice de protection, allant de 0.0 (aucune protection) à environ 0.75 (protection élevée).
- **L'axe vertical** : Indique les quatre niveaux de gravité.
- **Les points** : Chaque point représente un accident. L'opacité variable indique la superposition de plusieurs observations sur les mêmes coordonnées.
- **La ligne noire** : Représente la tendance globale (régression linéaire) de la gravité en fonction de l'augmentation du niveau de protection.

Observations clés :

- **Tendance à la baisse** : La droite de régression affiche une pente négative. Cela signifie que statistiquement, plus l'indice de protection augmente, plus la gravité moyenne des accidents a tendance à diminuer.

- **Concentration sur les faibles indices :** Une forte densité de points, toutes gravités confondues, est observée entre les indices 0.0 et 0.4. C'est dans cette zone que l'on retrouve la majorité des accidents de gravité 3 et 4.
- **Réduction de la sévérité aux indices élevés :** Pour les indices supérieurs à 0.6, on note une disparition progressive des accidents de gravité 4. À l'extrémité droite du graphique (indice 0.75), les accidents se stabilisent au niveau de gravité 2.
- **Dispersion importante :** Malgré la tendance, on observe des accidents de gravité 1 et 2 sur toute l'étendue de l'indice de protection, montrant que d'autres facteurs influencent également l'issue d'une collision.

Interprétation : L'analyse confirme l'efficacité des mesures de protection sur la réduction de la sévérité des accidents. La pente descendante de la droite de régression valide l'hypothèse selon laquelle l'amélioration des infrastructures de sécurité contribue directement à "amortir" la gravité des chocs.

Il est particulièrement notable que les protections les plus élevées (indice > 0.6) semblent agir comme un filtre contre les événements les plus tragiques (gravité 4), ramenant les conséquences vers un niveau modéré. Cependant, la présence de nombreux points à faible indice mais de faible gravité (1 ou 2) suggère que si une bonne protection réduit les risques, une mauvaise protection ne condamne pas systématiquement à un accident grave, soulignant le rôle complémentaire du comportement des usagers.




FIGURE 2.16 – Indice de protection vs gravité des accidents (Scatter plot avec régression)

2.3.6 Gravité moyenne par situation critique

Le graphique ci-dessous analyse la gravité moyenne des accidents (Severity) en fonction de quatre types de zones à risque ou situations critiques (*High_Risk_Junction*, *Crossing_Without_Signal*, *Is_Railway_Area*, *High_Activity_Zone*), à l'aide d'un diagramme en barres.

Structure du graphique :

- **L'axe horizontal :** Identifie les quatre environnements critiques sélectionnés pour l'étude.
- **L'axe vertical :** Indique le niveau de gravité moyenne des accidents, sur une échelle allant de 0.0 à plus de 2.0.
- **Les barres :** La hauteur de chaque barre de couleur correspond à la valeur moyenne de gravité calculée pour chaque situation spécifique.

Observations clés :

- **Gravité maximale aux intersections à haut risque :** La situation *High_Risk_Junction* présente la gravité moyenne la plus élevée, culminant à environ 2.3.
- **Zones ferroviaires :** La catégorie *Is_Railway_Area* suit de près avec une gravité moyenne dépassant 2.1, soulignant le danger inhérent à la proximité des voies ferrées.
- **Situations à risque modéré :** Les catégories *Crossing_Without_Signal* (passages sans signalisation) et *High_Activity_Zone* (zones à forte activité) affichent des niveaux de gravité quasi identiques, légèrement supérieurs à 2.0.

Interprétation : Les résultats mettent en évidence que toutes les zones critiques identifiées génèrent des accidents d'une gravité moyenne supérieure au niveau 2. Les **intersections à haut risque** se distinguent nettement comme les points les plus dangereux de l'infrastructure, probablement en raison de la complexité des flux de circulation et de la vitesse potentielle des véhicules lors des collisions latérales ou frontales.

L'écart observé entre les intersections (*High_Risk_Junction*) et les passages sans signalisation (*Crossing_Without_Signal*) suggère que la configuration géométrique et le volume de trafic d'une zone pèsent davantage sur la sévérité de l'accident que la seule absence de signalisation. Enfin, la gravité élevée en zone ferroviaire rappelle que les accidents impliquant des infrastructures fixes lourdes ou des passages à niveau conservent une intensité particulièrement forte.




FIGURE 2.17 – Gravité moyenne par situation critique (Bar chart)

2.3.7 Effet cumulatif des infrastructures sur la gravité

Le graphique présente l'évolution de la gravité moyenne des accidents en fonction du nombre d'équipements d'infrastructure présents sur les lieux (allant de 0 à 6), à l'aide d'un graphique linéaire (*line plot*).

Structure du graphique :

- **L'axe horizontal** : Indique le nombre total d'équipements de sécurité ou d'infrastructure recensés sur le site de l'accident.
- **L'axe vertical** : Mesure la gravité moyenne des accidents, sur une échelle allant de 0.5 à 4.5.
- **La ligne bleue** : Relie les points de données pour visualiser la tendance de la gravité à mesure que l'infrastructure se complexifie ou se renforce.

Observations clés :

- **Diminution initiale** : On observe une baisse de la gravité moyenne entre 0 et 2 équipements, passant d'environ 2.25 à un point bas proche de 2.05.
- **Stabilisation remarquable** : À partir de 2 équipements et jusqu'à 6, la courbe devient presque horizontale. La gravité moyenne se stabilise de manière constante autour de la valeur 2.1.
- **Faible amplitude globale** : Malgré le cumul des équipements, l'amplitude totale de variation reste faible (environ 0.2 point sur l'échelle de gravité), suggérant que le premier niveau d'équipement est le plus déterminant.

Interprétation : L'analyse de l'effet cumulatif révèle une loi de **rendements décroissants** en matière de sécurité infrastructurelle. L'ajout des deux premiers équipements semble avoir un impact réel pour réduire la sévérité moyenne des accidents, probablement en structurant l'espace routier et en prévenant les chocs les plus violents.

Cependant, au-delà de deux équipements, la multiplication des infrastructures ne semble plus réduire davantage la gravité moyenne. Cette stabilisation suggère qu'une fois un seuil de protection minimal atteint, la sévérité des accidents résiduels est dictée par d'autres facteurs (vitesse, comportement humain, météo) que l'infrastructure ne peut plus compenser. Pour le planificateur, cela indique qu'une couverture de base bien répartie est plus efficace qu'une accumulation excessive d'équipements sur un même point.




FIGURE 2.18 – Effet cumulatif des infrastructures sur la gravité moyenne (Line plot)

2.4 Analyse temporelle & saisonnalité

2.4.1 Distribution horaire du volume d'accidents

Le graphique illustre l'évolution du nombre total d'accidents en fonction de l'heure de la journée (cycle de 24 heures), à l'aide d'un graphique linéaire avec grille de lecture.

Structure du graphique :

- **L'axe horizontal (Heure) :** Représente les heures de la journée, de 0h00 à 23h00.
- **L'axe vertical (Nombre d'accidents) :** Indique le volume absolu d'accidents enregistrés, allant de moins de 10 000 à près de 60 000.
- **La courbe bleue :** Permet de visualiser les cycles de montée et de descente de l'accidentologie sur une journée type.

Observations clés :

- **Pic matinal prononcé** : On observe une augmentation fulgurante de l'accidentologie dès 5h00 du matin, culminant à un premier sommet entre 7h00 et 8h00 avec environ 59 000 accidents.
- **Creux méridien** : Après 8h00, le volume chute brutalement pour se stabiliser sur un plateau relatif entre 9h00 et 12h00 (autour de 35 000 accidents).
- **Second pic de l'après-midi** : Une nouvelle phase de croissance s'amorce après 12h00, atteignant un second maximum entre 16h00 et 17h00 (environ 58 000 accidents).
- **Accalmie nocturne** : Le nombre d'accidents diminue de manière continue après 17h00 pour atteindre son point le plus bas à 3h00 du matin (moins de 10 000 accidents).

Interprétation : L'analyse met en évidence une corrélation directe entre le volume d'accidents et les **heures de pointe** du trafic pendulaire. Les deux pics majeurs correspondent précisément aux horaires d'entrée (7h-8h) et de sortie (16h-17h) de bureau ou d'école. Cette hausse s'explique non seulement par la densité accrue de véhicules, mais aussi par le stress et la précipitation caractéristiques de ces créneaux.

Le plateau observé durant la matinée suggère un trafic plus fluide ou une typologie d'usagers différente (livraisons, déplacements professionnels hors domicile-travail). Enfin, la chute drastique durant la nuit reflète la réduction naturelle de l'activité humaine, bien que la gravité individuelle de chaque accident nocturne puisse être supérieure (vitesse, alcool), le volume global, lui, reste minimal.




FIGURE 2.19 – Évolution horaire du nombre d'accidents sur 24 heures (Line plot)

2.4.2 Répartition hebdomadaire du volume d'accidents

Le graphique présente le nombre total d'accidents enregistrés pour chaque jour de la semaine (du lundi au dimanche), à l'aide d'un diagramme en barres.

Structure du graphique :

- **L'axe horizontal (Jour) :** Énumère les sept jours de la semaine en anglais (*Monday* à *Sunday*).
- **L'axe vertical (Nombre d'accidents) :** Mesure le volume d'accidents, avec une échelle allant de 0 à 140 000 événements.
- **Les barres :** La hauteur de chaque barre bleue reflète la quantité totale d'accidents cumulés pour le jour concerné.

Observations clés :

- **Activité soutenue en semaine :** Du lundi au vendredi, le volume d'accidents est élevé et relativement stable, se maintenant systématiquement au-dessus de 120 000 unités.
- **Pic d'accidentologie le vendredi :** Le vendredi (*Friday*) enregistre le volume le plus important de la semaine, frôlant les 140 000 accidents.
- **Chute drastique le week-end :** On observe une rupture nette à partir du samedi (*Saturday*), où le nombre d'accidents chute de près de moitié par rapport au vendredi (environ 65 000). Le dimanche (*Sunday*) marque le point le plus bas de la semaine avec moins de 60 000 accidents enregistrés.

Interprétation : Cette distribution souligne une corrélation évidente entre l'accidentologie et les cycles de l'activité socio-professionnelle. La stabilité des volumes durant la semaine (*working days*) s'explique par la densité constante du trafic lié aux trajets domicile-travail et aux activités logistiques.

Le pic du vendredi peut être interprété comme la conjonction du trafic pendulaire habituel et des départs en week-end, augmentant ainsi le flux de véhicules et potentiellement la fatigue des conducteurs. À l'inverse, l'effondrement des chiffres le samedi et le dimanche reflète la réduction massive du trafic routier global. Bien que les accidents de week-end soient parfois statistiquement plus graves (vitesse, loisirs), leur fréquence absolue est beaucoup plus faible en raison de la diminution du nombre de véhicules en circulation.




FIGURE 2.20 – Volume total des accidents par jour de la semaine (Bar chart)

2.4.3 Comparaison du volume d'accidents : Semaine vs Week-end par gravité

Le graphique présente une comparaison du volume total d'accidents entre les jours de la semaine et le week-end, segmentée par niveau de gravité (échelle de 1 à 4), à l'aide d'un diagramme en barres empilées.

Structure du graphique :

- **L'axe horizontal** : Distingue les deux périodes d'analyse : la semaine (*Semaine*) et la fin de semaine (*Week-end*).
- **L'axe vertical** : Indique le nombre total d'accidents cumulés.
- **Les segments colorés** : Chaque couleur représente un niveau de gravité, du bleu (niveau 1) au rouge (niveau 4), permettant de visualiser la proportion de chaque sévérité au sein du volume global.

Observations clés :

- **Disparité majeure du volume global** : Le nombre total d'accidents en semaine dépasse les 600 000, tandis qu'il est inférieur à 150 000 pour le week-end. Cette différence massive reflète l'intensité du trafic lié aux activités professionnelles.
- **Dominance de la gravité 2** : Dans les deux cas, le segment orange (gravité 2) est largement majoritaire. Il constitue le socle principal de l'accidentologie, quelle que soit la période.
- **Proportionnalité de la gravité 3** : Le segment vert (gravité 3) occupe une place visuelle proportionnellement similaire dans les deux barres, suggérant que le risque d'accident grave ne disparaît pas avec la baisse du trafic.

- **Faible représentation des extrêmes** : Les gravités 1 (bleu) et 4 (rouge) apparaissent comme des liserés très fins au sommet et à la base des barres, confirmant leur rareté statistique par rapport aux niveaux intermédiaires.

Interprétation : L'analyse confirme que l'exposition au risque est intrinsèquement liée au flux de circulation : la semaine, période de forte activité économique et pendulaire, concentre la grande majorité des événements.

Toutefois, la structure de la gravité reste remarquablement stable entre les deux périodes. Cela indique que, bien que le nombre d'accidents chute drastiquement le week-end, la nature des collisions (en termes de sévérité) ne change pas fondamentalement. Le système routier produit le même profil de risque (majoritairement de niveau 2), mais à une fréquence réduite, ce qui suggère que les mécanismes de protection ou les types de routes empruntés conservent des caractéristiques similaires tout au long de la semaine.




FIGURE 2.21 – Comparaison du volume et de la gravité : Semaine vs Week-end (Bar chart empilé)

2.4.4 Analyse spatio-temporelle : Heatmap des accidents (Heure × Jour)

Le graphique présente une vision croisée de l'accidentologie sur une semaine complète à l'aide d'une **carte de chaleur** (heatmap), permettant d'identifier les zones de concentration temporelle critique.

Structure du graphique :

- **L'axe horizontal (Heure)** : Détaille les 24 heures de la journée (de 0 à 23).

- **L'axe vertical (Jour) :** Énumère les jours de la semaine, du vendredi au mercredi.
- **L'échelle de couleur :** L'intensité du rouge indique le volume d'accidents. Les teintes les plus sombres correspondent aux fréquences les plus élevées (dépassant les 10 000 événements par cellule).

Observations clés :

- **Les deux couloirs de pointe :** On observe distinctement deux bandes verticales sombres sur les jours de semaine (du lundi au vendredi). La première se situe entre 7h00 et 8h00, et la seconde, plus étendue, entre 15h00 et 17h00.
- **Le creux méridien :** Une zone plus claire est visible aux alentours de 9h00 et 10h00, indiquant une accalmie relative entre les deux pics de trafic majeurs.
- **Spécificité du week-end :** Les lignes correspondant au samedi et au dimanche sont nettement plus claires sur l'ensemble du cycle de 24 heures, confirmant une baisse globale de l'accidentologie.
- **Stabilité inter-journalière :** Les profils horaires sont quasiment identiques du lundi au jeudi, suggérant une routine de mobilité très structurée.

Interprétation : Cette heatmap confirme que le facteur déterminant de l'accidentologie est l'intensité de l'activité pendulaire. Les "zones chaudes" coïncident parfaitement avec les périodes de transition domicile-travail. La prédominance du rouge foncé durant l'après-midi (16h-17h) par rapport au matin pourrait s'expliquer par une fatigue accrue des conducteurs en fin de journée de travail ou par une plus grande dispersion des horaires de sortie.

L'homogénéité du graphique durant la semaine de travail démontre que le risque est systémique et lié aux infrastructures saturées durant ces créneaux. À l'inverse, l'aspect diffus du week-end montre que les accidents y sont moins liés à une saturation temporelle et plus probablement à des facteurs de loisirs ou de déplacements sporadiques.

2.4.5 Évolution historique du volume d'accidents (2016-2023)

Le graphique retrace l'évolution mensuelle du nombre d'accidents sur une période de sept ans, de début 2016 à début 2023, à l'aide d'une série temporelle.

Structure du graphique :

- **L'axe horizontal (Temps) :** Indique les années de l'étude, de 2016 à 2023.
- **L'axe vertical (Nombre d'accidents) :** Mesure le volume mensuel des événements, allant de 0 à 20 000.
- **La courbe bleue :** Visualise les fluctuations, les tendances à long terme et les ruptures cycliques de l'accidentologie.

Observations clés :




FIGURE 2.22 – Concentration des accidents par heure et par jour de la semaine (Heatmap)

- **Croissance initiale et plateau (2016–2020) :** On observe une phase de montée progressive du volume d'accidents entre 2016 et 2017, suivie d'une période de relative stabilité oscillant entre 7 500 et 10 000 accidents par mois jusqu'au début de 2020.
- **Rupture majeure en 2020 :** Une chute brutale et historique est visible au premier semestre 2020, où le volume d'accidents plonge sous la barre des 5 000. Ce creux exceptionnel coïncide avec les mesures de confinement global.
- **Forte volatilité post-2020 :** À partir de fin 2020, le graphique montre une reprise très marquée avec une instabilité croissante. On enregistre des pics records dépassant les 17 500 accidents en 2021 et 2022.
- **Baisse récente (2023) :** La courbe se termine par une chute abrupte au début de l'année 2023, ramenant les chiffres à des niveaux historiquement bas.

Interprétation : L'évolution historique révèle que l'accidentologie n'est pas un phénomène statique mais extrêmement sensible aux contextes globaux. La période 2016-2019 montre un régime de croisière "normal". La rupture de 2020 illustre l'impact immédiat de la réduction forcée de la mobilité sur la sécurité routière.

Plus surprenante est la période post-2020, qui affiche une augmentation significative du volume d'accidents par rapport aux niveaux d'avant-crise. Cette recrudescence pourrait traduire des changements dans les habitudes de conduite, une augmentation du trafic après les restrictions, ou des modifications dans les méthodes de collecte de données. Enfin, le plongeon final en 2023 suggère soit un succès soudain des politiques de sécurité, soit, plus probablement, un décalage dans la remontée des données pour l'année en cours.




FIGURE 2.23 – Évolution mensuelle des accidents entre 2016 et 2023 (Time series plot)

2.4.6 Analyse de la saisonnalité du volume d'accidents

Le graphique ci-dessous présente la distribution du nombre total d'accidents selon les quatre saisons de l'année, à l'aide d'un diagramme en barres.

Structure du graphique :

- **L'axe horizontal (Saison) :** Répertorie les saisons classées par ordre décroissant de volume : Hiver (*Winter*), Automne (*Fall*), Printemps (*Spring*) et Été (*Summer*).
- **L'axe vertical (Nombre d'accidents) :** Indique le volume global d'accidents, s'étendant de 0 à plus de 200 000 événements.
- **Les barres :** La hauteur de chaque barre bleue illustre la fréquence cumulée des accidents pour chaque période saisonnière.

Observations clés :

- **Prédominance de l'hiver :** L'hiver (*Winter*) est la saison la plus accidentogène de l'étude, enregistrant un pic dépassant les 225 000 accidents.
- **Dangerosité de l'automne :** L'automne (*Fall*) occupe la deuxième position avec un volume significatif d'environ 210 000 accidents.
- **Saisons plus clémentes :** Le printemps (*Spring*) et l'été (*Summer*) présentent des chiffres nettement inférieurs et très proches l'un de l'autre, se situant aux alentours de 170 000 accidents.

Interprétation : L'analyse saisonnière révèle une hausse marquée de l'accidentologie durant les périodes froides. La nette domination de l'**hiver** peut être attribuée à la dégradation des conditions de conduite : réduction de la visibilité (nuits plus longues), chaussées glissantes (neige, verglas) et conditions météorologiques défavorables.

La transition vers l'automne montre également une dangerosité accrue, potentiellement liée au retour des précipitations et au changement d'heure influençant la vigilance des usagers. À l'inverse, les volumes plus faibles enregistrés durant le printemps et l'été suggèrent que des conditions climatiques plus stables et une meilleure luminosité contribuent à une réduction relative du nombre d'événements, malgré une possible augmentation du trafic lié aux vacances estivales.




FIGURE 2.24 – Répartition du volume total d'accidents par saison (Bar chart)

2.4.7 Analyse de la durée des accidents par période de la journée

Le graphique présente la distribution de la durée des accidents (exprimée en minutes) selon quatre périodes de la journée (*Evening, Afternoon, Morning, Night*), à l'aide d'un boxplot.

Structure du graphique :

- **L'axe vertical** : Mesure la durée de l'accident en minutes, plafonnée à 300 minutes pour une meilleure lisibilité.
- **La ligne médiane** : Indique la durée centrale des interventions pour chaque période.
- **La boîte (interquartile)** : Représente les 50 % centraux des observations. Sa hauteur traduit la variabilité des durées habituelles.
- **Les points sombres (outliers)** : Au sommet des moustaches, ils indiquent une concentration massive d'accidents de très longue durée (dépassant les 250 minutes).

Observations clés :

- **Médiane la plus élevée la nuit :** La période nocturne (*Night*) présente la médiane la plus haute (environ 85 minutes), indiquant que les accidents durant cette phase tendent à durer plus longtemps.
- **Variabilité maximale l'après-midi :** La boîte associée à l'après-midi (*Afternoon*) est la plus étendue vers le haut, suggérant une plus grande disparité dans les temps d'intervention ou de résolution.
- **Durées plus courtes le matin :** La période du matin (*Morning*) affiche la médiane la plus basse (environ 60 minutes) et la boîte la plus compacte, signe d'une résolution plus rapide des incidents.
- **Présence systématique de valeurs extrêmes :** Toutes les périodes affichent une densité très importante de points au-delà de 250 minutes, formant des barres verticales sombres. Cela montre que les interventions prolongées sont fréquentes quel que soit le moment de la journée.

Interprétation : L'analyse montre que la temporalité influence significativement la durée de gestion des accidents. La durée supérieure observée la **nuit** peut s'expliquer par une visibilité réduite, des délais d'alerte plus longs ou une gravité souvent plus élevée nécessitant des interventions complexes.

Le matin, malgré un volume d'accidents élevé (comme vu précédemment), les durées sont plus courtes, ce qui pourrait traduire une meilleure réactivité des services de secours aux heures de pointe ou des accidents plus légers (accrochages liés aux embouteillages). Enfin, la présence constante d'accidents très longs (outliers) souligne que la complexité de certains sinistres (dommages aux infrastructures, enquêtes) outrepassa le simple facteur de l'heure de la journée.




FIGURE 2.25 – Distribution de la durée des accidents selon la période de la journée (Box plot)

Conclusion générale

Cette analyse exploratoire met en évidence que l'accidentologie routière résulte d'une interaction complexe entre facteurs spatiaux, temporels, infrastructurels et comportementaux. Les résultats montrent que la majorité des accidents survient dans des conditions météorologiques normales, confirmant que la météo n'est pas un facteur déterminant de la gravité, laquelle reste majoritairement concentrée autour du niveau 2.

La distribution spatiale des accidents est fortement corrélée à la densité de population et à l'intensité du trafic. Les régions Sud et Ouest concentrent la majorité des accidents, tandis que les États les plus peuplés enregistrent les volumes les plus élevés, principalement pour des raisons structurelles plutôt que pour un risque intrinsèquement supérieur.

L'analyse révèle également des différences notables entre zones urbaines et rurales : bien que moins fréquents, les accidents ruraux présentent une gravité plus variable et parfois plus élevée, soulignant la vulnérabilité des routes à grande vitesse. Les infrastructures jouent un rôle clé dans la limitation de la sévérité, avec une efficacité démontrée des dispositifs de sécurité, bien qu'un seuil d'efficacité apparaisse au-delà duquel les gains deviennent marginaux.

Enfin, la dimension temporelle confirme une forte dépendance aux cycles d'activité humaine. Les heures de pointe et les jours ouvrables concentrent l'essentiel des accidents, tandis que les périodes nocturnes et hivernales sont associées à des conditions de conduite plus complexes.

Dans l'ensemble, ces résultats soulignent que la réduction durable des accidents routiers nécessite une approche globale combinant aménagement raisonné des infrastructures, gestion du trafic et prise en compte du comportement des usagers, plutôt qu'une focalisation sur un seul facteur isolé.

